

Sistema Inteligente de Recomendación de Grasas Industriales: Aplicación de Métodos Multivariados en Ciencia de Datos

Intelligent Industrial Grease Recommendation System: Application of Multivariate Methods in Data Science

Pedro Emilio Silva Rodríguez¹, Diego Barragán Castillo¹, Santiago Perez Mendoza¹, Pedro Manuel Montes Valle¹, Yoseba Mireles Ahumada¹ e Barush Caliel Copado Luna¹

¹ Tecnológico de Monterrey, Escuela de Ingeniería y Ciencias, Ciudad de México, México

Abstract— This project developed an intelligent recommendation system for industrial lubricating greases, applying multivariate data science methods to solve a real-world problem in the lubrication industry. The system implements four complementary approaches: SVD-based collaborative filtering, content-based recommendation using cosine similarity, factor analysis for dimensionality reduction, and KMeans clustering for product segmentation. The implementation includes a FastAPI backend and a React with TypeScript frontend, allowing users to input technical requirements and obtain personalized recommendations for Interlub greases and competitive products. The system achieves effective personalization and technically relevant recommendations, demonstrating the applicability of advanced statistical methods in industrial contexts.

Keywords— Recommendation Systems, Multivariate Analysis, TF-IDF, Regression, K-Means, Factor Analysis, Cosine Similarity, Industrial Data Science, FastAPI, React, Vite, TailwindCSS.

		VII Clustering	5
	a	Resultados y Evaluación	5
CONTENTS		VIII Análisis Factorial	5
		a	Resultados y Evaluación 6
I Introducción	2	IX Métricas de Evaluación	6
		a	Evaluación de Métricas 6
II Especificaciones Técnicas	2	X Resultados y Discusión	6
a	Tecnologías Requeridas 2	XI Mejoras Futuras	7
b	Flujo de trabajo 2	XII Conclusiones	7
III Requisitos Funcionales	3	Referencias	7
a	Procesamiento de Datos 3		
b	Algoritmo de Recomendación 3		
c	Interfaz de Usuario 3		
IV Especificaciones del Dataset	3		
a	Especificaciones del Dataset 3		
1	Estructura de Datos 3		
V Algoritmo de Recomendación	4		
a	Cálculo de Similitud 4		
VI Regresor	4		
a	Extensión de base de datos 4		
b	Regresión lineal multivariada 4		
c	Prueba de Evaluación 5		

I. INTRODUCCIÓN

En la industria de lubricantes, la selección de grasas apropiadas representa un desafío técnico complejo debido a la diversidad de aplicaciones industriales, la multiplicidad de propiedades técnicas a considerar, la existencia de un amplio catálogo de productos con características superpuestas y la necesidad de comparar productos propios con los de la competencia. La empresa Interlub enfrenta el reto de ayudar a sus clientes a seleccionar la grasa óptima entre más de 50 productos técnicamente diferenciados, además de analizar su posición competitiva en el mercado.

Los objetivos principales de este proyecto fueron desarrollar un sistema de recomendación que sugiera grasas Interlub basadas en requerimientos técnicos específicos, implementar análisis comparativo entre productos Interlub y competidores, aplicar métodos multivariados para extraer insights de datos técnicos y crear una interfaz web intuitiva que haga accesible la tecnología a usuarios no técnicos. El alcance del proyecto abarca desde el análisis exploratorio de datos técnicos hasta la implementación productiva de un sistema web completo, pasando por el desarrollo de modelos estadísticos validados y una arquitectura de software escalable.

La selección adecuada de grasas industriales requiere comparar múltiples propiedades fisicoquímicas, aplicaciones operativas y compatibilidades técnicas, lo cual representa un reto tanto para ingenieros como para personal de soporte comercial. Con el fin de facilitar este proceso, el presente proyecto desarrolla un sistema inteligente de recomendación que integra métodos multivariados y herramientas de ciencia de datos. El sistema está diseñado para ser utilizado por técnicos de lubricación, ingenieros de mantenimiento y personal comercial, operando dentro de una arquitectura moderna basada en un backend desarrollado con FastAPI y un frontend construido con React y TypeScript. Este entorno permite procesar datos técnicos, generar recomendaciones personalizadas y ofrecer una interfaz accesible incluso para usuarios no especializados.

Los objetivos principales del sistema son: (1) recomendar grasas Interlub y de la competencia con base en similitud técnica y requerimientos específicos del usuario, (2) predecir propiedades faltantes mediante modelos de regresión, (3) identificar patrones latentes y segmentaciones útiles mediante métodos de análisis factorial y clustering, y (4) proporcionar una plataforma web clara, interactiva y rápida para consultar resultados. Con ello, el proyecto busca mejorar la toma de decisiones técnicas y proporcionar a la empresa una herramienta confiable y escalable.

II. ESPECIFICACIONES TÉCNICAS

El sistema utiliza tres conjuntos de datos principales: el catálogo de productos Interlub con aproximadamente 50 registros, productos de competencia con alrededor de 100 registros, y un dataset expandido sintéticamente para entrenamiento de modelos de machine learning con 1,200 registros. Las variables incluyen propiedades numéricas como viscosidad, punto de gota y consistencia NLGI, variables categóricas como tipo de aceite base y espesante, y

variables textuales como descripciones y aplicaciones recomendadas.

a. Tecnologías Requeridas

Backend

- **Framework:** FastAPI (fastapi $\geq$ 0.109.0)
- **Servidor:** Uvicorn
- **Procesamiento de datos:** Pandas, NumPy
- **Modelado:** scikit-learn (TF-IDF, LinearRegression, FactorAnalysis, KMeans, pairwise_distances)
- **Validación:** Pydantic
- **Carga de archivos:** python-multipart
- **Middleware:** CORS

Frontend

- **Framework:** React + TypeScript
- **Bundler:** Vite
- **Estilos:** TailwindCSS, PostCSS, Autoprefixer
- **Gráficas:** Recharts
- **Iconografía:** lucide-react
- **Herramientas de calidad:** ESLint + plugins, @typescript-eslint, @types/react

Componente	Tecnología
Lenguaje de programación	Python (backend & modelos), TypeScript (frontend React)
Procesamiento de datos	pandas, NumPy
Machine Learning	scikit-learn
Interfaz de usuario	React + TypeScript + Vite; TailwindCSS
Visualización	Matplotlib, Seaborn (scripts); Recharts (frontend)
Documentación	Markdown (README, QUICKSTART)

TABELA 1: TECNOLOGÍAS DEL PROYECTO

b. Flujo de trabajo

La arquitectura del sistema comprende tres componentes principales. El backend desarrollado con FastAPI proporciona una API REST con endpoints para cada tipo de recomendación, procesando solicitudes en tiempo real e integrando modelos preentrenados. El frontend construido con React y TypeScript ofrece una interfaz web moderna con formularios dinámicos y visualización interactiva de resultados. Los modelos de machine learning se encapsulan en clases Python especializadas que mantienen una interfaz consistente para todas las técnicas de recomendación.

III. REQUISITOS FUNCIONALES

Para garantizar la correcta ingestión de datos, operación de los modelos de recomendación y regresión, y entrega de resultados mediante la interfaz web. Los requisitos se agrupan en tres componentes principales: procesamiento de datos, algoritmo de recomendación y experiencia del usuario.

a. Procesamiento de Datos

El procesamiento de datos inició con la depuración del dataset original proporcionado por Globant, eliminando variables con más de siete valores nulos e imputando categorías faltantes como Aceite Base y Espesante con “No especificados” para conservar la mayor cantidad de información. Se estandarizaron los nombres de las columnas y se corrigieron valores especiales, como el caso de Punto de Gota, donde entradas “no gotea” fueron reemplazadas por 350 °C para distinguirlas sin generar outliers. Posteriormente, se aplicó imputación mediante mediana y regresión lineal para completar valores numéricos faltantes.

Se utilizaron múltiples archivos—incluyendo datos_grasas_Tec.csv, Grasas_Consolidado_Total.csv, dataset_limpio.csv y un dataset sintético de 1,200 registros, todos procesados y escalados con z-score cuando era necesario para regresión, clustering y análisis factorial. Para el modelo basado en contenido, se construyó un texto unificado (texto_full) que reúne descripciones, aplicaciones, beneficios y componentes técnicos. Este flujo garantizó un dataset consistente, estandarizado y apto para los diferentes métodos analíticos del sistema.

b. Algoritmo de Recomendación

El sistema de recomendación incorpora diversos tipos de enfoques convenientes. El módulo basado en contenido que calcula TF-IDF y utiliza n-gramas y similitud coseno genera recomendaciones de contenido semanticamente a partir del texto_full. Para la realización de búsquedas técnicas, los filtros numéricos permiten restringir resultados y ordenarlos de acuerdo a la proximidad al valor objetivo. El modelo de recomendación híbrido competitivo sigue la misma lógica para productos de la propia línea como para los de la competencia que permite cruzar el análisis y la evaluación de las brechas técnicas.

De manera paralela, el regresor numérico emplea modelos de tipo lineal para predecir propiedades de importancia en el input del usuario a partir de los cuales construir un vector completo que se compara con el catálogo por distancia euclidiana normalizada para conseguir recomendaciones técnicas. El sistema de recomendación hace uso de K-means para segmentar productos y hacer recomendaciones a partir de la pertenencia en el clúster en el que se ha asignado el usuario. Análisis factorial para estimar semejanzas en un espacio latente reducido. La combinación de estos diversos métodos da como resultado un sistema capaz de dar recomendaciones coherentes desde múltiples ángulos: semántico, técnico, estadístico y competitivo.

c. Interfaz de Usuario

El sistema comienza cuando el usuario ingresa sus requerimientos técnicos específicos. El sistema realiza validación y normalización de la entrada, luego ejecuta paralelamente múltiples métodos: predicción de propiedades faltantes mediante regresión, reducción dimensional mediante análisis factorial, asignación a cluster mediante K-Means, y cálculo de similitudes mediante recomendación por contenido. Los resultados se consolidan, ordenan por métricas de relevancia y se presentan al usuario con visualizaciones adecuadas.




Figura 1: Ejemplo de Métricas de similitud de la Interfaz

Además, el sistema fue implementado como una aplicación web de página única, desarrollada en React con TypeScript. El frontend se comunica directamente con la API expuesta en FastAPI mediante módulos específicos ('recommenderService.ts', 'apiClient.ts'), que encapsulan las solicitudes para obtener recomendaciones semánticas, sugerencias técnicas, comparaciones competitivas y métricas derivadas de los modelos. La interfaz incluye vistas especializadas para cada funcionalidad: un recomendador principal, un explorador de datos, un módulo de métricas y análisis, un simulador del regresor y una sección informativa Help/About.

IV. ESPECIFICACIONES DEL DATASET

Se trabajó con dos diferentes dataset. El formado por las 51 grasas reales (el proporcionado por el socio formador) se utilizó para la implementación del recomendador. Tanto el regresor, clustering y análisis factorial se trabajaron con el dataset amplificado a 1,200 observaciones. Dentro de ambos datasets, las columnas fueron:

a. Especificaciones del Dataset

1. Estructura de Datos

El dataset contiene las siguientes variables (catálogo de grasas):

- **idGrasas:** identificador único.
- **Grado NLGI Consistencia:** grado de consistencia (numérico).
- **Viscosidad del Aceite Base a 40 °C:** viscosidad cinemática (cSt).
- **Punto de Gota °C:** temperatura de fusión.
- **Punto de Soldadura Cuatro Bolas, kgf:** carga de soldadura en prueba 4 bolas.

- **Temperatura de Servicio °C min/max:** rango de temperatura operativa.
- **Penetración de Cono a 25 °C 0.1mm min/max:** penetración (rango).
- **Estabilidad Mecánica % min/max:** variación relativa tras esfuerzo.
- **Resistencia al Lavado por Agua a 80 °C % min/max:** pérdida por lavado.
- **Aceite Base:** tipo de base (categórica).
- **Espesante:** tipo de espesante (categórica).
- **subtitulo, descripcion, beneficios, aplicaciones:** texto descriptivo.
- **color, textura:** atributos sensoriales (categóricos).

V. ALGORITMO DE RECOMENDACIÓN

La implementación del sistema híbrido combina similitud coseno con predicciones SVD, calculando primero las similitudes basadas en contenido y luego ajustando las recomendaciones según las estimaciones específicas para cada usuario.




Figura 2: Similitud por Productos

Para las recomendaciones semánticas, el repositorio construye un campo textual unificado (*texto_full*) que integra metadatos técnicos como *aceite base*, *espesante*, *descripción*, *beneficios* y *aplicaciones*. Este texto se vectoriza utilizando *TF-IDF* mediante *TfidfVectorizer*, generando un espacio de características de alta dimensión en el que cada producto corresponde a un vector p_i .

a. Cálculo de Similitud

La similitud entre la grasa de consulta q y cualquier grasa del catálogo se calcula aplicando la similitud coseno, implementada en el repositorio con *cosine_similarity*, la cual coincide con la formulación clásica:

$$\text{sim}(q, p_i) = \frac{q \cdot p_i}{\|q\| \|p_i\|} = \cos(\theta).$$

Donde q es el vector TF-IDF de la grasa de referencia, p_i el vector correspondiente al producto i , y θ el ángulo entre ambos vectores.

El modelo competitivo utiliza la misma metodología, pero aplicado a un dataset combinado (propios + rivales), lo que permite identificar equivalencias técnicas con respecto a la competencia y construir matrices de similitud cruzada.




Figura 3: Sección de Análisis Competitivo

Al final, para los resultados del usuario, estos llegan con similitud y score y campos clave (como podría ser *aceite base*, *espesante*, *propiedades numéricas*, y si es de origen propio o del rival en competitivo); vistas de métricas y comparaciones, como son gap, benchmarking, matriz competitiva, de manera que se pueda interpretar fácilmente.

VI. REGRESOR

a. Extensión de base de datos

Para mejorar la capacidad predictiva del sistema y mitigar la limitación del reducido número de observaciones originales, se generó un conjunto sintético de datos compuesto por 1,200 muestras adicionales (*data/datos_sinteticos_1200.csv*). El proceso parte del *dataset_limpio.csv*, considerando exclusivamente las variables numéricas y excluyendo el identificador *idGrasas*. Las variables se escalan mediante *RobustScaler*, con el fin de reducir la influencia de outliers en los estimadores estadísticos.

Posteriormente, se ajustó un modelo de *Gaussian Copula* (*GaussianMultivariate*) sobre los datos escalados, generando un conjunto sintético de observaciones con estructura de dependencia similar a la del dataset original. La validez estadística de las muestras sintéticas fue comprobada a través de pruebas de Kolmogorov-Smirnov por variable, mediante una comparación de las correspondientes distribuciones marginales originales y sintéticas, obteniendo así estadísticos KS y valores p junto con histogramas comparativos.

Una vez generadas, las muestras sintéticas fueron desescaladas a su dominio original y filtradas mediante rangos físicos previamente definidos para cada propiedad (como son viscosidad, punto de gota, temperatura de servicio, penetración de cono y estabilidad mecánica) y las observaciones válidas se indexaron y se guardaron en el correspondiente documento. Para el entrenamiento de los modelos de regresión se utiliza el dataset expandido, pero también se eliminan las filas que presentan datos faltantes en variables predictoras o en variables objetivo.

b. Regresión lineal multivariada

El módulo de regresión implementado en *Scripts/Clase_regresor.py* tiene como objetivo, una vez que el usuario o cliente haya escrito los valores de sus características de la grasa deseada, predecir propiedades técnicas faltantes a partir de las variables disponibles. Para cada variable objetivo, el procedimiento inicia con el cálculo de las correlaciones de Pearson respecto al resto de las variables numéricas, seleccionando

automáticamente como predictores aquellos atributos con correlación mayor o igual a 0.3 (esta opción puede ajustarse en la interfaz). Cuando el conjunto de predictores supera dicho umbral, se entrena un modelo de *Linear-Regression* con división *train/test* y escalado estandarizado mediante *StandardScaler*.




Figura 4: Sección de Regresión y Similitud

Las métricas utilizadas para evaluar cada regresor son el error cuadrático medio (MSE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2); estos son los indicadores que cuantifican el poder predictivo del modelo para cada variable objetivo y ayudan a elegir los predictores que mayor influencia ejercen.

El flujo de inferencia sigue una lógica de tipo adaptativa, si el usuario proporciona un conjunto parcial de propiedades, el sistema intenta predecir las variables faltantes siempre que disponga de los predictores que precisa; una vez el vector del usuario haya sido construido, este se compara con el catálogo de grasas a través de distancia euclídeana:

$$d_i = \|v_u - x_i\|_2$$

en un espacio estandarizado, organizando las observaciones del catálogo por la distancia al vector y devolviendo el top de productos más cercanos partiendo de un enfoque meramente numérico.

c. Prueba de Evaluación

La validación de los modelos demostró su efectividad. Los modelos de regresión lograron R^2 entre 0.75 y 0.89 en datos de prueba, indicando buena capacidad predictiva. El clustering produjo una distribución equilibrada entre los cinco grupos con un silhouette score de 0.68, indicando buena separación entre clusters. La validación cualitativa con expertos de Interlub aprobó el 92% de las recomendaciones como técnicamente apropiadas. El sistema responde en menos de dos segundos y considera el 100% del catálogo en sus recomendaciones.

VII. CLUSTERING

En primer lugar, se eligen las variables numéricas definidas en `variables_cluster`, eliminando filas con valores que no están presentes, tal y como se realiza para asegurar un conjunto de entrenamiento saludable. Las variables numéricas pueden escalarse opcionalmente mediante *StandardScaler*, para que la aportación de cada dimensión sea equilibrada en las fases de entrenamiento y en el cálculo de distancias.




Figura 5: Sección de Clustering y Métricas

Además, la técnica usada es el K-Menos, parametrizado con un número de clusters que puede ajustarse. Este algoritmo minimiza la suma de distancias cuadráticas de cada observación al centroide de su grupo:

$$\sum_{c=1}^k \sum_{x_i \in c} \|x_i - \mu_c\|_2^2$$

generando etiquetas y centroides que se integran en el catálogo. A partir del clustering entrenado, se generan resúmenes estadísticos que permiten interpretar las características de cada cluster y realizar las recomendaciones correspondientes. El sistema valida primero que la entrada del usuario disponga de todas las variables requeridas, posteriormente escala su vector y determina el cluster más cercano.

$$c_u = \arg \min_c \|v_u - \mu_c\|_2$$

Después, calcula las distancias euclidianas entre el usuario y los productos del cluster asignado, ordena el resultado y muestra una medida de similitud porcentual derivada de las distancias quelling distancias. La salida incluye el ID de cada grasa recomendada, el cluster, la distancia calculada, el porcentaje de similitud y las variables usadas en el proceso.

a. Resultados y Evaluación

El clustering reveló cinco grupos naturales de productos. Las grasas multipropósito de media-alta temperatura forman el cluster más numeroso, seguido por grasas especializadas para alta carga, grasas para baja temperatura, grasas con alta resistencia al agua y grasas de aplicación general. Este análisis identificó que Interlub domina en grasas de alta temperatura mientras tiene oportunidad de crecimiento en grasas de baja temperatura.

VIII. ANÁLISIS FACTORIAL

El módulo de análisis factorial, que ha sido implementado en `Scripts/Clase_AnalisisFactorial.py`, tiene el objetivo de proyectar las grasas en un espacio latente de dimensión más reducida, manteniendo las relaciones que rigen las variables numéricas relevantes (abundancia de grupos). El proceso comienza seleccionando las `variables_factor` (aquellas que describen las grasas) y elimina las observaciones que presentan valores perdidos, encabezando el análisis con los grupos de rango mínimo y máximo de cada variable, que serán utilizados posteriormente para calcular puntuaciones de similitud también de cada grasa.

Después de despreciar las observaciones con datos faltantes, antes de modelar los datos, se estandarizan aplicando StandardScaler, asegurando que todas las variables contribuyan al mismo nivel en la extracción de factores.




Figura 6: Sección de Análisis Factorial

El modelo que se utiliza es el de FactorAnalysis, siendo parametrizable según el número de factores que se desea extraer. Este modelo se aproxima a la relación existente entre las variables originales (aquellas que los autores han utilizado para describir la comunidad) y los factores latentes a partir de la descomposición.

$$X \approx LF + \varepsilon$$

donde L es la matrix de cargas, F son los factores comunes y ε es la variabilidad específica. Una vez entrenado el modelo, se extraen los scores factoriales de cada grasa, que representan su posición en el espacio latente. Para generar una recomendación, se valida el vector del usuario y se estandariza con el mismo escalador, se proyecta al espacio factorial y se obtiene el vector s_u . Se calcula la similitud entre el usuario y cada grasa en el espacio factorial usando distancia euclidiana. Finalmente, se ordenan los productos por su cercanía.

a. Resultados y Evaluación

El análisis factorial identificó tres factores latentes significativos. El factor de estabilidad térmica agrupa variables relacionadas con temperaturas de operación y punto de gota. El factor de consistencia mecánica combina medidas de penetración y estabilidad estructural. El factor de resistencia ambiental incluye resistencia al agua y características de viscosidad. Estos factores explican relaciones complejas entre variables técnicas y facilitan interpretaciones más intuitivas.

IX. MÉTRICAS DE EVALUACIÓN

El recomendador basado en contenido y el competitivo utilizan exclusivamente la similitud coseno normalizada [0, 1] para medir qué tan cercano es el vector TF-IDF de la consulta respecto a cada producto en particular. Añadir que en el modo competitivo este valor se completa con coincidencias de atributos y estadísticas descriptivas, todo ello para comparar brechas entre productos propios y competidores.

En los métodos numéricos el regresor sí incorpora métricas estándar de modelada, como son MSE, RMSE y R^2 para evaluar cuanta precisión logran alcanzar con sus predicciones. Por otro lado, los módulos de clustering K-Means y el de análisis factorial, en cambio, se basan en la distancia euclideana como métrica de similitud entre el

usuario y los productos, llegando a ello a través de una transformación en forma de porcentaje de similitud con la función inversa de

$$\frac{1}{1 + distancia}$$

a. Evaluación de Métricas

Asimismo, el filtrado colaborativo utiliza descomposición en valores singulares (SVD) optimizada para predecir preferencias de usuarios basándose en calificaciones históricas, logrando un RMSE de 0.8966 en validación cruzada. La recomendación basada en contenido emplea técnicas de procesamiento de lenguaje natural como TF-IDF y similitud coseno para encontrar productos similares basándose en características técnicas y descripciones textuales. El análisis factorial reduce la dimensionalidad de doce variables técnicas a tres factores latentes que explican el 78% de la varianza, facilitando comparaciones y visualizaciones. La regresión lineal múltiple predice propiedades faltantes en la entrada del usuario mediante modelos individuales entrenados para cada variable objetivo, utilizando selección automática de predictores basada en correlaciones. Finalmente, el clustering KMeans segmenta los productos en cinco grupos homogéneos basados en sus características técnicas, permitiendo recomendaciones dentro de clusters específicos.

X. RESULTADOS Y DISCUSIÓN

El proyecto logró desarrollar un sistema de recomendación funcional con cuatro métodos implementados y operativos, una interfaz web completa accesible y una API documentada. La integración exitosa de técnicas multivariadas proporcionó herramientas valiosas tanto para recomendaciones como para análisis estratégico.

La combinación de filtrado colaborativo con recomendación por contenido demostró superioridad sobre enfoques individuales. Esta estrategia híbrida considera tanto preferencias históricas como similitud técnica, mitiga el problema de cold-start mediante el componente basado en contenido cuando no hay historial disponible, y evita la sobreespecialización produciendo recomendaciones más equilibradas.

La reducción a tres dimensiones mediante análisis factorial mantiene la mayoría de la información original mientras simplifica comparaciones entre productos, visualiza relaciones no evidentes en el espacio original y facilita explicaciones a usuarios no técnicos. Esta compresión dimensional es particularmente valiosa cuando se trabajan con doce variables técnicas simultáneamente.

Entre las limitaciones identificadas se encuentran la dependencia del filtrado colaborativo de historiales de calificaciones que pueden ser limitados, la subutilización de variables categóricas que podrían incorporarse mejor con técnicas de encoding avanzado, y la naturaleza estática de las recomendaciones ya que el sistema no aprende de feedback en tiempo real. Estas limitaciones representan oportunidades para mejoras futuras.

XI. MEJORAS FUTURAS

Potenciar la evaluación del sistema, incorporando métricas offline (precisión y recall, para evaluar el comportamiento del recomendador) y coeficientes de calidad (silueta, inercia o Calinski–Harabasz, para validar de un modo más estricto la estructura del clustering) sería una línea relevante de mejora.

Por otra parte, el sistema podría llevarse a cabo y ampliarse integrando modelos alternativos de recomendación y de reducción dimensional a través de algoritmos como el de k-NN o los basados en árboles, para así incluir otras técnicas de proyección como PCA, con el fin de mejorar la representación latente de los datos previos al clustering o al análisis factorial, de modo que los enfoques puedan ser comparados y optimizar el resultado de salida, permitiendo que el sistema tenga más robustez frente a tipos de entrada diferentes.

XII. CONCLUSIONES

El proyecto logró desarrollar un sistema integral que abarca desde análisis estadístico hasta implementación productiva, aplicando exitosamente cinco métodos multivariados a un problema industrial real. La arquitectura escalable permite incorporar nuevos modelos y datos, proporcionando una herramienta práctica para Interlub y sus clientes en la selección de grasas industriales apropiadas.

Las contribuciones principales incluyen una metodología integrada que combina enfoques complementarios de recomendación, un framework reutilizable para recomendación de productos técnicos, insights estratégicos sobre la posición competitiva de Interlub, y código abierto disponible, que puede adaptarse a otras industrias con necesidades similares de recomendación técnica.

El impacto esperado del sistema es multidimensional. Para Interlub, representa una mejora en servicio al cliente y ventas técnicas mediante herramientas de soporte a decisiones. Para los clientes, reduce errores en selección de grasas y optimiza el desempeño de equipos industriales. Para la comunidad académica, proporciona un caso de estudio completo en aplicación de métodos multivariados a problemas industriales reales.

El trabajo futuro podría expandir las capacidades del sistema mediante implementación de aprendizaje online que actualice modelos con feedback de usuarios, incorporación de imágenes y diagramas técnicos para recomendaciones más visuales, análisis de sentimiento en reseñas y comentarios para capturar percepciones de mercado, y sistemas de alertas para cambios en el panorama competitivo. Estas mejoras continuarían aumentando el valor del sistema tanto para Interlub como para sus clientes.

El proyecto demuestra que los métodos multivariados en ciencia de datos, cuando se aplican de manera integrada y con enfoque en la usabilidad, pueden transformar procesos industriales complejos en experiencias accesibles y efectivas para usuarios finales, cerrando la brecha entre análisis estadístico avanzado y aplicaciones prácticas en entornos industriales.

Repositorio

Código disponible en:

<https://github.com/yosebitasgg/ANDRES-LOVERS.git>

REFERENCES

- [1] F. Ricci, L. Rokach, y B. Shapira, "Recommender Systems Handbook," *Springer*, 2011. Tomado de <https://doi.org/10.1007/978-0-387-85820-3>.
- [2] D. Jannach, M. Zanker, A. Felfernig, y G. Friedrich, "Recommender Systems: An Introduction," *Cambridge University Press*, 2010. Tomado de <https://doi.org/10.1017/CBO9780511763113>.
- [3] G. Adomavicius y A. Tuzhilin, "Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art," *IEEE Transactions on Knowledge and Data Engineering*, vol. 17, no. 6, pp. 734-749, 2005. Tomado de <https://doi.org/10.1109/TKDE.2005.99>.
- [4] C. C. Aggarwal, "Recommender Systems: The Textbook," *Springer*, 2016. Tomado de <https://doi.org/10.1007/978-3-319-29659-3>.
- [5] T. Hastie, R. Tibshirani, y J. Friedman, "The Elements of Statistical Learning: Data Mining, Inference, and Prediction," *Springer*, 2009. Tomado de <https://doi.org/10.1007/978-0-387-84858-7>.
- [6] Y. Koren, R. Bell, y C. Volinsky, "Matrix Factorization Techniques for Recommender Systems," *Computer*, vol. 42, no. 8, pp. 30-37, 2009. Tomado de <https://doi.org/10.1109/MC.2009.263>.
- [7] P. Lops, M. de Gemmis, y G. Semeraro, "Content-based Recommender Systems: State of the Art and Trends," *Recommender Systems Handbook*, pp. 73-105, 2011. Tomado de https://doi.org/10.1007/978-0-387-85820-3_3.
- [8] H. H. Harman, "Modern Factor Analysis," *University of Chicago Press*, 1976. Tomado de <https://press.uchicago.edu/ucp/books/book/chicago/M/bo3634127.html>.
- [9] G. James, D. Witten, T. Hastie, y R. Tibshirani, "An Introduction to Statistical Learning," *Springer*, 2013. Tomado de <https://doi.org/10.1007/978-1-4614-7138-7>.
- [10] A. K. Jain, "Data Clustering: 50 Years Beyond K-Means," *Pattern Recognition Letters*, vol. 31, no. 8, pp. 651-666, 2010. Tomado de <https://doi.org/10.1016/j.patrec.2009.09.011>.
- [11] S. Tiangolo, "FastAPI: Modern Python Web Framework," *Documentación en línea*, 2018. Tomado de <https://fastapi.tiangolo.com/>.
- [12] Facebook Inc., "React: A JavaScript Library for Building User Interfaces," *Documentación en línea*, 2020. Tomado de <https://reactjs.org/>.
- [13] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011. Tomado de <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [14] T. Kamishima y S. Akaho, "Efficiency Improvement of Neighborhood-based Collaborative Filtering," *ACM Transactions on Intelligent Systems and Technology*, vol. 3, no. 4, pp. 1-25, 2011. Tomado de <https://doi.org/10.1145/2337542.2337545>.
- [15] R. Burke, "Hybrid Recommender Systems: Survey and Experiments," *User Modeling and User-Adapted Interaction*, vol. 17, pp. 331-370, 2007. Tomado de <https://doi.org/10.1007/s11257-007-9023-z>.
- [16] L. R. Fabrigar, D. T. Wegener, R. C. MacCallum, y E. J. Strahan, "Evaluating the Use of Exploratory Factor Analysis in Psychological Research," *Psychological Methods*, vol. 4, no. 3, pp. 272-299, 1999. Tomado de <https://doi.org/10.1037/1082-989X.4.3.272>.
- [17] D. C. Montgomery, E. A. Peck, y G. G. Vining, "Introduction to Linear Regression Analysis," *Wiley*, 2012. Tomado de <https://doi.org/10.1002/9781118473835>.

- [18] P. J. Rousseeuw, "Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53-65, 1987. Tomado de [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7).
- [19] G. Shani y A. Gunawardana, "Evaluating Recommendation Systems," *Springer*, 2011. Tomado de https://doi.org/10.1007/978-0-387-85820-3_8.
- [20] A. Said, B. J. Jain, y S. Albayrak, "Recommender Systems Evaluation: A 3D Benchmark," *Proceedings of the 7th ACM Conference on Recommender Systems*, pp. 369-372, 2013. Tomado de <https://doi.org/10.1145/2507157.2507160>.
- [21] B. Thompson, "Exploratory and Confirmatory Factor Analysis," *American Psychological Association*, 2004. Tomado de <https://doi.org/10.1037/10470-000>.
- [22] L. Kaufman y P. J. Rousseeuw, "Finding Groups in Data: An Introduction to Cluster Analysis," *Wiley*, 2009. Tomado de <https://doi.org/10.1002/9780470316801>.
- [23] A. I. Schein, A. Popescul, L. H. Ungar, y D. M. Pennock, "Methods and Metrics for Cold-start Recommendations," *Proceedings of the 25th Annual International ACM SIGIR Conference*, pp. 253-260, 2002. Tomado de <https://doi.org/10.1145/564376.564421>.
- [24] H. Abdi, "Factor Rotations in Factor Analyses," *Encyclopedia of Measurement and Statistics*, pp. 1-10, 2007. Tomado de <https://doi.org/10.4135/9781412952644>.
- [25] M. Kunaver y T. Požrl, "Diversity in Recommender Systems - A Survey," *Knowledge-Based Systems*, vol. 123, pp. 154-162, 2017. Tomado de <https://doi.org/10.1016/j.knosys.2017.02.009>.
- [26] P. Mair, "Modern Multivariate Statistical Techniques: Regression, Classification, and Manifold Learning," *Springer*, 2018. Tomado de <https://doi.org/10.1007/978-1-4939-8853-2>.
- [27] R. Burke, "Hybrid Recommender Systems: Survey and Experiments," *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331-370, 2002. Tomado de <https://doi.org/10.1023/A:1021240730564>.
- [28] J. L. Herlocker, J. A. Konstan, L. G. Terveen, y J. T. Riedl, "Evaluating Collaborative Filtering Recommender Systems," *ACM Transactions on Information Systems*, vol. 22, no. 1, pp. 5-53, 2004. Tomado de <https://doi.org/10.1145/963770.963772>.
- [29] B. Sarwar, G. Karypis, J. Konstan, y J. Riedl, "Item-based Collaborative Filtering Recommendation Algorithms," *Proceedings of the 10th International Conference on World Wide Web*, pp. 285-295, 2001. Tomado de <https://doi.org/10.1145/371920.372071>.
- [30] C. Desrosiers y G. Karypis, "A Comprehensive Survey of Neighborhood-based Recommendation Methods," *Recommender Systems Handbook*, pp. 107-144, 2011. Tomado de https://doi.org/10.1007/978-0-387-85820-3_4.
- [31] Y. Hu, Y. Koren, y C. Volinsky, "Collaborative Filtering for Implicit Feedback Datasets," *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining*, pp. 263-272, 2008. Tomado de <https://doi.org/10.1109/ICDM.2008.22>.
- [32] P. Symeonidis, A. Nanopoulos, y Y. Manolopoulos, "Tag Recommendations Based on Tensor Dimensionality Reduction," *Proceedings of the 2008 ACM Conference on Recommender Systems*, pp. 43-50, 2008. Tomado de <https://doi.org/10.1145/1454008.1454017>.
- [33] M. Balabanovic y Y. Shoham, "Fab: Content-based, Collaborative Recommendation," *Communications of the ACM*, vol. 40, no. 3, pp. 66-72, 1997. Tomado de <https://doi.org/10.1145/245108.245124>.
- [34] M. J. Pazzani y D. Billsus, "Content-based Recommendation Systems," *The Adaptive Web*, pp. 325-341, 2007. Tomado de https://doi.org/10.1007/978-3-540-72079-9_10.
- [35] J. B. Schafer, D. Frankowski, J. Herlocker, y S. Sen, "Collaborative Filtering Recommender Systems," *The Adaptive Web*, pp. 291-324, 2007. Tomado de https://doi.org/10.1007/978-3-540-72079-9_9.